Salud mental frente a CNIO, con el mismo modelo entrenado.

Salud mental junta cuatro servicios del daily de mayo de 2026: DC_ (709 pacientes), ita_ (2 447), FJD_smartcrisis_2_0 (981) y SJD (51). En total, 4 188 pacientes y 874 558 días. CNIO son los 175 pacientes PMP de DB1, 51 972 días. No entran adalmed, afsp, cnio_caspar, das ni TMC, porque no están en estos daily. Tampoco GM ni DM. Se cuentan solo los días presentes en el daily.

Cuatro comprobaciones, ahora entre estas dos cohortes.

- Error de reconstrucción de los días observados.
- Ocupación de los 6 topics del LDA.
- Reparto de los 256 day-types dentro de cada cohorte.
- A nivel de paciente: cuántos códigos usa y cómo de lejos cae cada día.

1. Error de reconstrucción

Error absoluto medio y correlación entre el valor real y el reconstruido, solo en features observadas, en el espacio escalado del entrenamiento. No entra el fin de semana.

Cohorte	Pacientes	Días	MAE	Correlación
Salud mental	4 188	874 558	0,32	0,84
CNIO	175	51 972	0,36	0,77

Feature	Mental	CNIO
Inicio del sueño	0,16	0,19
Distancia	0,34	0,41
Tiempo en casa	0,35	0,37
Duración del sueño	0,40	0,38
Caminar	0,35	0,40
Uso de app	0,34	0,35
N.º de lugares	0,30	0,35
Pasos	0,34	0,46

> Las dos cohortes se reconstruyen. La correlación es 0,84 en salud mental y 0,77 en CNIO. El ajuste es un poco peor en CNIO, sobre todo en pasos (0,46 frente a 0,34). La duración del sueño es la única feature en la que el error de salud mental supera al de CNIO.

2. Ocupación de topics

LDA de 6 topics ya entrenado (vdec25). Cada paciente es la bolsa de códigos de sus días. La ocupación de la cohorte pondera por el número de días. Todos los códigos usados están en el diccionario. El topic 0 tiene como código principal el 126.

Cohorte	T0	T1	T2	T3	T4	T5
Salud mental	0,41	0,04	0,27	0,08	0,14	0,07
CNIO	0,10	0,19	0,25	0,17	0,15	0,16

> La mezcla no es la misma. Salud mental pone el 41 % de los días en el topic 0 y el 27 % en el topic 2. CNIO deja el topic 0 en el 10 % y reparte el resto entre 0,15 y 0,25, con el máximo en el topic 2 (0,25). La divergencia de Jensen–Shannon entre las dos mezclas es 0,10.

3. Reparto de los 256 day-types

Códigos distintos que aparecen, número efectivo (exponencial de la entropía) y masa de los 10 más usados. La divergencia de Jensen–Shannon entre las dos ocupaciones de códigos es 0,11.

Cohorte	Códigos usados	N efectivo	Masa top-10	Código 1
Salud mental	256 / 256	131	34 %	126 (7,6 %)
CNIO	254 / 256	197	13 %	76 (1,7 %)

> Ninguna cohorte colapsa el codebook. Salud mental usa los 256 códigos, con un número efectivo de 131; el top-10 cubre el 34 % y el código 126 es el más frecuente, con solo el 7,6 % de los días. CNIO es más abierto: número efectivo 197 y el código más usado, el 76, cubre el 1,7 %.

4. Nivel de paciente

Medianas por paciente. Códigos distintos en su seguimiento, fracción de días del código más usado, distancia euclídea del embedding continuo a ese código, y masa del topic dominante.

Cohorte	Códigos / paciente	Parte del 1.º	Distancia	Topic dominante
Salud mental	46	11 %	3,4	0,68
CNIO	80	7 %	6,1	0,58

El margen mediano entre el código elegido y el segundo es 0,77 en salud mental y 0,96 en CNIO. La probabilidad del ganador es 0,34 y 0,45. Hay un código claro, y el día no está pegado al prototipo. En CNIO cada día queda más lejos.

> Ningún grupo queda en un solo perfil. La mediana es 46 códigos distintos por paciente en salud mental y 80 en CNIO. El código más usado cubre el 11 % y el 7 % de los días de esa persona. El perfil es una mezcla: más apoyada en un topic en salud mental, más repartida en CNIO.

Lectura

- Reconstrucción: las dos cohortes se reconstruyen (correlación 0,84 y 0,77). El ajuste es algo mejor en salud mental.
- Topics: salud mental carga el topic 0 (41 %) y el 2 (27 %). CNIO deja el topic 0 en el 10 % y reparte el resto. JS = 0,10.
- Day-types: se usan 256 y 254 códigos. CNIO está más abierto (número efectivo 197 frente a 131).
- Paciente: decenas de códigos por persona. La asignación de cada día gana con margen y no etiqueta todo el seguimiento.

En el comportamiento raw, CNIO duerme menos, pasa más tiempo en casa, hace más deporte, camina menos, da más pasos y usa más la app (FDR < 0,05). Distancia y número de lugares no se separan. La hora de inicio del sueño es detectable por el tamaño de la muestra, con una diferencia de medias casi nula (d = 0,002).