¿El modelo captura información específica y los perfiles tienen grados de libertad?

Mismo VQ-VAE entrenado (a0) sobre los daily de salud mental (mayo 2026) y sobre los daily CNIO de DB1. Salud mental: deterioro cognitivo (CI), conducta alimentaria (ED1), Gregorio Marañón (GM) y riesgo de suicidio (SR), 90 pacientes cada una (semilla 123). Trastorno mental común (TMC): los 51 pacientes que hay. CNIO: los 175 pacientes de DB1, todos con servicio PMP. Se cuentan solo los días presentes en el daily.

Cuatro comprobaciones.

- Error de reconstrucción: el modelo tiene que reconstruir los días de oncología y de salud mental, sin quedarse con un solo contexto.
- Ocupación de topics: la mezcla de los 6 topics del LDA tiene que cambiar entre CNIO y salud mental.
- Reparto de los 256 day-types: dentro de cada cohorte el codebook no puede estar colapsado en unos pocos códigos.
- Nivel de paciente: cada persona ocupa un subconjunto de day-types, y el código asignado a cada día no es un empate.

1. Error de reconstrucción

Para cada día y cada feature observada se compara el valor real con la salida del decoder, en el espacio escalado del entrenamiento (log1p y estandarización en las features positivas). El error es el promedio del valor absoluto. La correlación es entre el valor real y el reconstruido, en las mismas posiciones observadas. No entran los huecos de calendario ni el fin de semana, que el pipeline rellena solo.

Cohorte	N	MAE	Correlación
CI deterioro cognitivo	90	0,29	0,84
ED1 conducta alimentaria	90	0,31	0,83
GM Gregorio Marañón	90	0,32	0,86
SR riesgo de suicidio	90	0,34	0,82
TMC trastorno mental común	51	0,27	0,86
CNIO	175	0,36	0,77

MAE por feature, en el mismo espacio escalado. El sueño de inicio se reconstruye muy bien en todas. Donde CNIO se separa más es en pasos (0,46 frente a 0,32–0,37) y en caminar (0,40 frente a 0,32–0,35).

Feature	CI	ED1	GM	SR	TMC	CNIO
Inicio del sueño	0,15	0,15	0,16	0,18	0,15	0,19
Distancia	0,36	0,32	0,44	0,39	0,25	0,41
Tiempo en casa	0,33	0,31	0,36	0,37	0,26	0,37
Duración del sueño	0,35	0,39	0,39	0,45	0,35	0,38
Caminar	0,34	0,35	0,34	0,34	0,32	0,40
Uso de app	0,28	0,30	0,30	0,36	0,26	0,35
N.º de lugares	0,27	0,31	0,35	0,27	0,28	0,35
Pasos	0,34	0,34	0,37	0,35	0,32	0,46

> Las dos cohortes se reconstruyen. La correlación va de 0,77 (CNIO) a 0,86 (TMC y Marañón). El ajuste es más prieto en salud mental, sobre todo en TMC, y un poco peor en CNIO. No hay un contexto que el modelo ignore.

2. Ocupación de topics

Se aplica el LDA de 6 topics ya entrenado sobre secuencias de day-types (modelo vdec25, vocabulario de 255 códigos). Cada paciente es un documento: la bolsa de códigos de sus días. La ocupación de la cohorte es la media de esas mezclas, ponderada por el número de días. Todos los códigos usados aquí están en el diccionario (fracción fuera de vocabulario = 0). El topic 0 tiene como código principal el 126.

Cohorte	T0	T1	T2	T3	T4	T5
CI	0,43	0,05	0,17	0,05	0,17	0,13
ED1	0,48	0,03	0,27	0,03	0,15	0,05
GM	0,43	0,06	0,15	0,06	0,16	0,13
SR	0,34	0,04	0,26	0,12	0,13	0,11
TMC	0,74	0,05	0,04	0,03	0,11	0,03
CNIO	0,10	0,19	0,25	0,17	0,15	0,16

Divergencia de Jensen–Shannon entre esas mezclas (logaritmo natural). Dentro del bloque CI–ED1–GM el valor es 0,00–0,03. CNIO frente a ese bloque es 0,09–0,15. CNIO frente a TMC es 0,26. SR es el grupo mental más cercano a CNIO (0,06).

La mezcla de topics no es genérica. Salud mental carga el topic 0 (el del código 126): del 34 % en riesgo de suicidio al 74 % en TMC. CNIO deja ese topic en el 10 % y reparte el resto entre los otros cinco, ninguno por encima del 25 %. El LDA se entrenó con secuencias oncológicas; aun así, los días de salud mental caen en un topic distinto del que usa CNIO.

3. Reparto de los 256 day-types

Dentro de cada cohorte se cuenta cuántos de los 256 códigos aparecen, cuánta masa concentran los 10 más usados y el número efectivo de códigos (exponencial de la entropía). Un codebook colapsado tendría unos pocos códigos y un número efectivo cercano a 1.

Cohorte	Códigos usados	N efectivo	Masa top-10	Código 1
CI	255 / 256	105	39 %	126 (9,5 %)
ED1	255 / 256	109	37 %	126 (8,5 %)
GM	255 / 256	113	36 %	126 (9,0 %)
SR	255 / 256	159	25 %	126 (5,2 %)
TMC	251 / 256	54	54 %	126 (12,5 %)
CNIO	254 / 256	197	13 %	76 (1,7 %)

Ninguna cohorte colapsa el codebook: aparecen 251–255 códigos. CNIO es el espacio más abierto (número efectivo 197; el top-10 solo cubre el 13 %). Salud mental está más concentrada, y TMC es el caso más estrecho (número efectivo 54, top-10 del 54 %). Sigue habiendo decenas de códigos activos, no uno solo. El código 126 es el más usado en los cinco grupos mentales y no en CNIO.

4. Nivel de paciente

Por paciente: cuántos day-types distintos usa, qué fracción de sus días se queda el código más frecuente, y cómo de lejos cae el embedding continuo del código asignado (mediana de la distancia euclídea en el latente, y margen frente al segundo código). En topics, la masa del topic dominante de ese paciente.

Cohorte	Códigos / paciente	Parte del 1.º	Distancia	Topic dominante
CI	32	15 %	2,6	0,70
ED1	45	12 %	3,0	0,69
GM	40	15 %	3,3	0,68
SR	42	11 %	4,1	0,61
TMC	30	16 %	2,2	0,87
CNIO	80	7 %	6,1	0,58

Las cifras de códigos por paciente, parte del primero y distancia son medianas. El margen mediano entre el código elegido y el segundo va de 0,57 (TMC) a 0,98 (CNIO): la asignación no es un empate. La probabilidad del ganador, en cambio, queda entre 0,30 y 0,46. El día tiene un código claro, pero no está pegado al prototipo.

> Ningún paciente queda reducido a un solo perfil. En salud mental la mediana es 30–45 códigos distintos, y el más usado cubre el 11–16 % de los días. En CNIO la mediana es 80 códigos y el más usado cubre el 7 %. El perfil es una mezcla. En salud mental esa mezcla se apoya más en un topic; en CNIO está más repartida, y cada día queda más lejos de su código.

Lectura

- Reconstrucción: oncología y salud mental se reconstruyen, con correlación 0,77–0,86. El ajuste es algo mejor en salud mental.
- Topics: CNIO y salud mental no ocupan la misma mezcla. Salud mental carga el topic del código 126; CNIO lo deja en el 10 % y reparte el resto.
- Day-types: el codebook no está colapsado. CNIO usa muchos más códigos a la vez. TMC es la cohorte más concentrada y, aun así, tiene un número efectivo de 54.
- Paciente: cada persona ocupa decenas de day-types. El código del día gana con margen, sin ser una etiqueta única forzada para todo el seguimiento.

Los perfiles separan el contexto clínico y dejan grados de libertad reales. La representación es más holgada y más diversa en CNIO, y más prieta en salud mental, en particular en TMC. En el daily de mayo no están los grupos das, el segundo grupo de conducta alimentaria ni DM.